

Reconocimiento de imágenes biomédicas

A través del uso
de inteligencia artificial

Imágenes de fondo de ojo para la clasificación de
patologías retinianas

Por:
Diego Fernando Malagón
Jorge Miguel Acosta
Gabriel Santiago Murillo



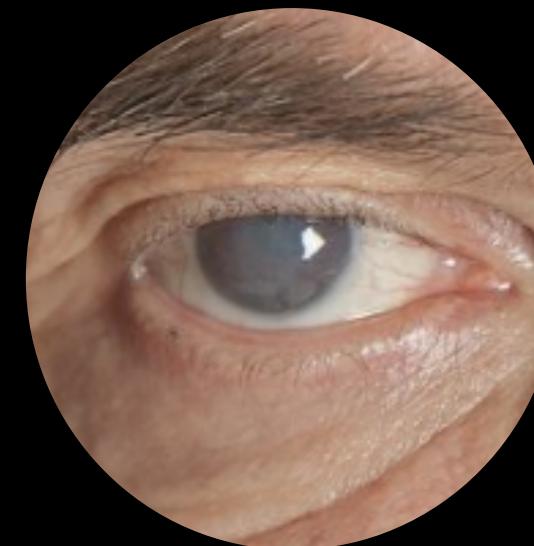


Contenidos.

- 1 Introducción
- 2 Metodología
- 3 Resultados esperados
- 4 Conclusiones
- 5 Perspectivas Futuras.
- 6 Bibliografía

MOTIVACIÓN Y CONTEXTO

La salud visual constituye un aspecto fundamental en la calidad de vida, por lo tanto una mayor eficiencia en la detección de enfermedades oculares, con la ayuda de la Inteligencia Artificial, supone un avance en la automatización y precisión del diagnóstico



Degeneración
macular



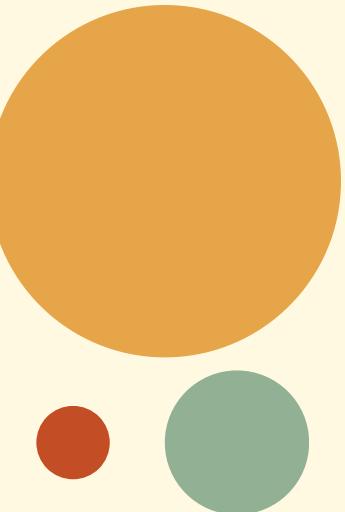
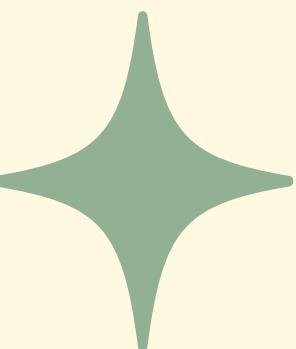
Retinopatía
diabética



Glaucoma

INTRODUCCIÓN

El enfoque propuesto en este proyecto se centra en aprovechar las capacidades de CNN para extraer patrones complejos y características relevantes de las imágenes de fondo de ojo



ESTADO DEL ARTE

- El enfoque propuesto en este proyecto se centra en aprovechar las capacidades de CNN para extraer patrones complejos y características relevantes de las imágenes de fondo de ojo Aplicaciones de IA en Oftalmología:
 - *Trabajo de Gulshan et al. (2016) demostró resultados comparables a expertos en retinopatía diabética.*
- Limitaciones de métodos actuales:
 - La clasificación no ofrece información sobre la localización de las lesiones.
 - La segmentación requiere anotaciones precisas y es costosa computacionalmente.
- Innovación del enfoque híbrido:
- Combinación de clasificación y técnicas interpretativas (saliency maps).



Metodología

Preparación de Datos

Ajuste de los datos para facilitar el proceso de convolucionado

Entrenamiento del Modelo

Entrenamiento del modelo utilizando generadores de datos

Validación final

Validación del rendimiento utilizando otro set de datos no utilizados anteriormente,

Adquisición de Datos

Recopilación un conjunto de imágenes de fondo de ojo provenientes de una base de datos.

Arquitectura de la Red Convolucional

Utilización de una arquitectura de red convolucional (CNN) para entrenar el modelo de clasificación

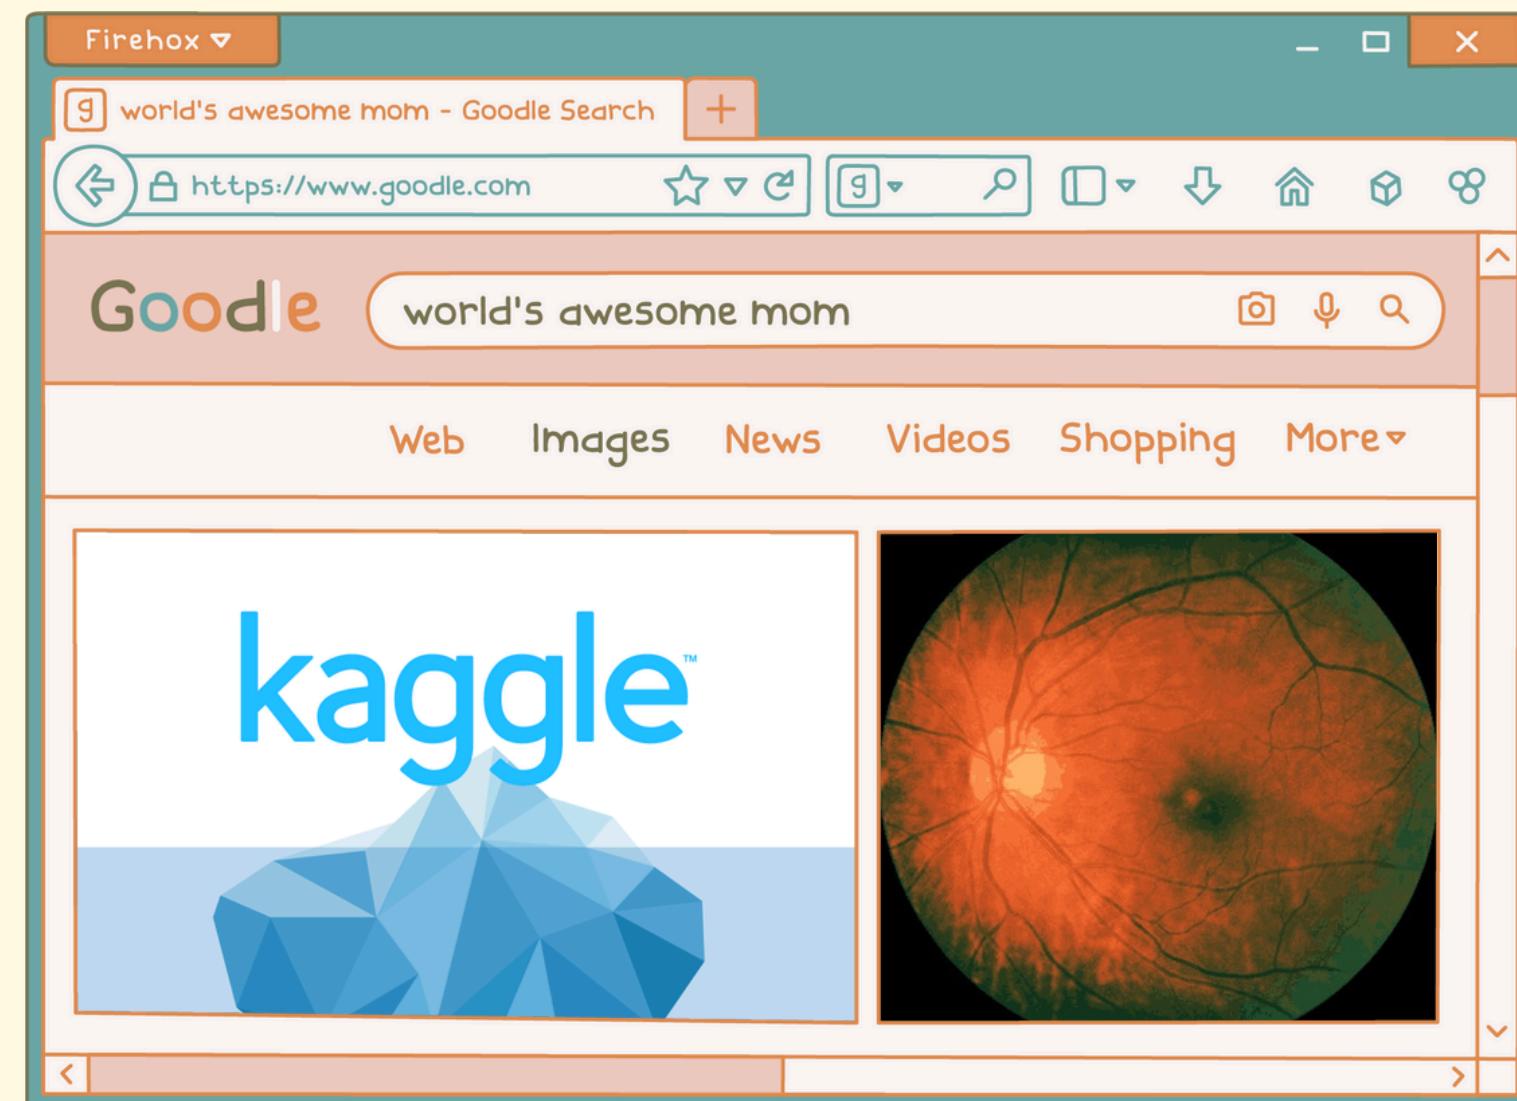
Evaluación del Modelo

Uso de métricas de rendimiento como la precisión, la sensibilidad, la especificidad y el AUC-ROC.

ADQUISICIÓN DE DATOS

- Retina Normal (1074)
 - Retinopatía Diabética (1098)
 - Catarata (1038)
 - Glaucoma (1007)
-

- Image Segmentation
- Equalize Histogram

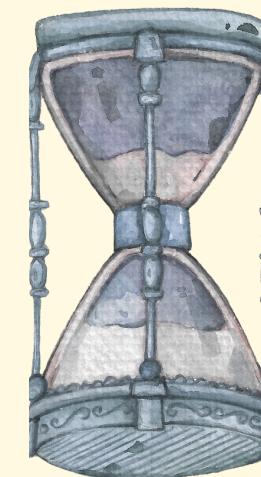


No

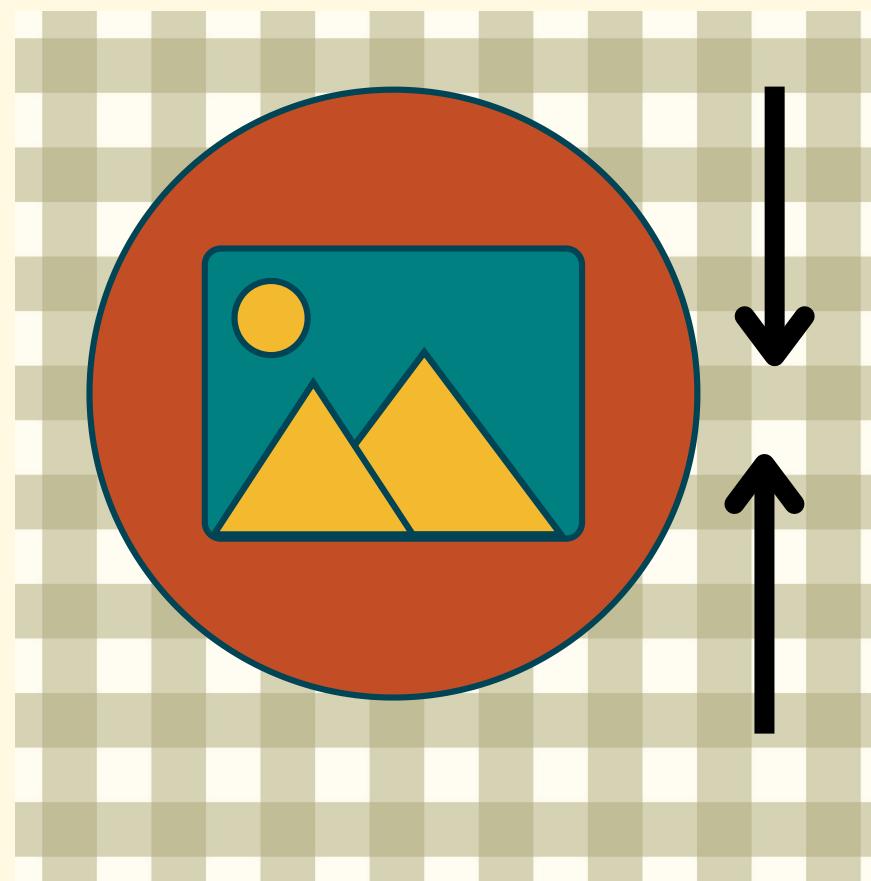
Yes



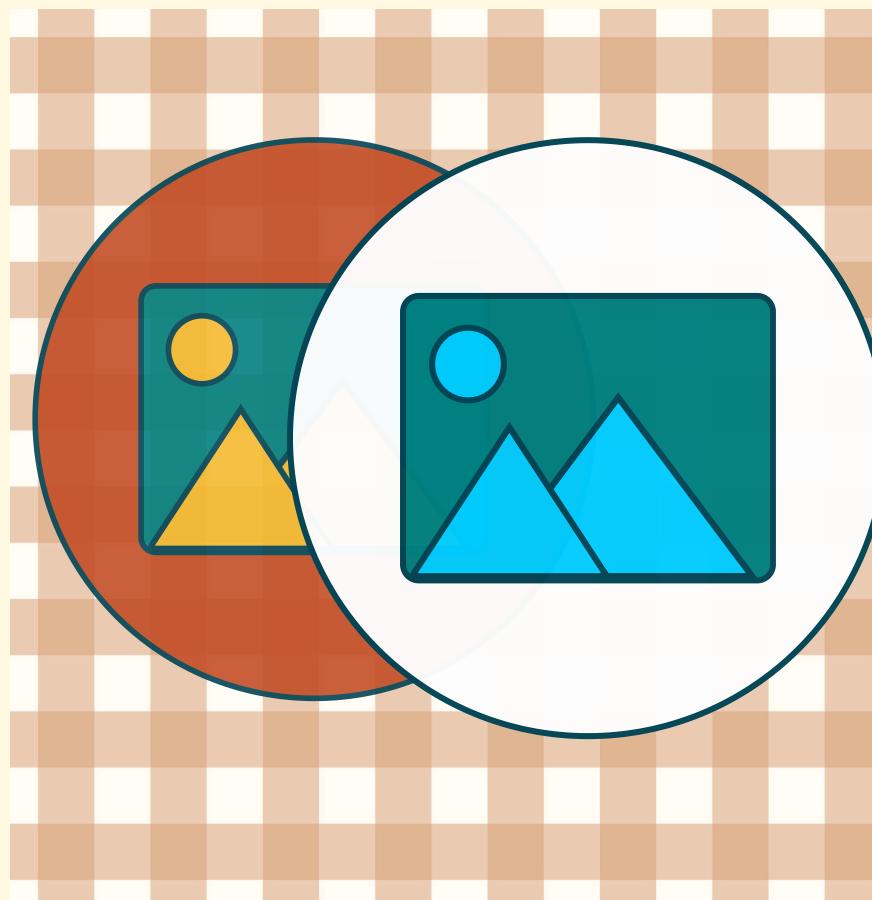
PREPARACIÓN DE DATOS



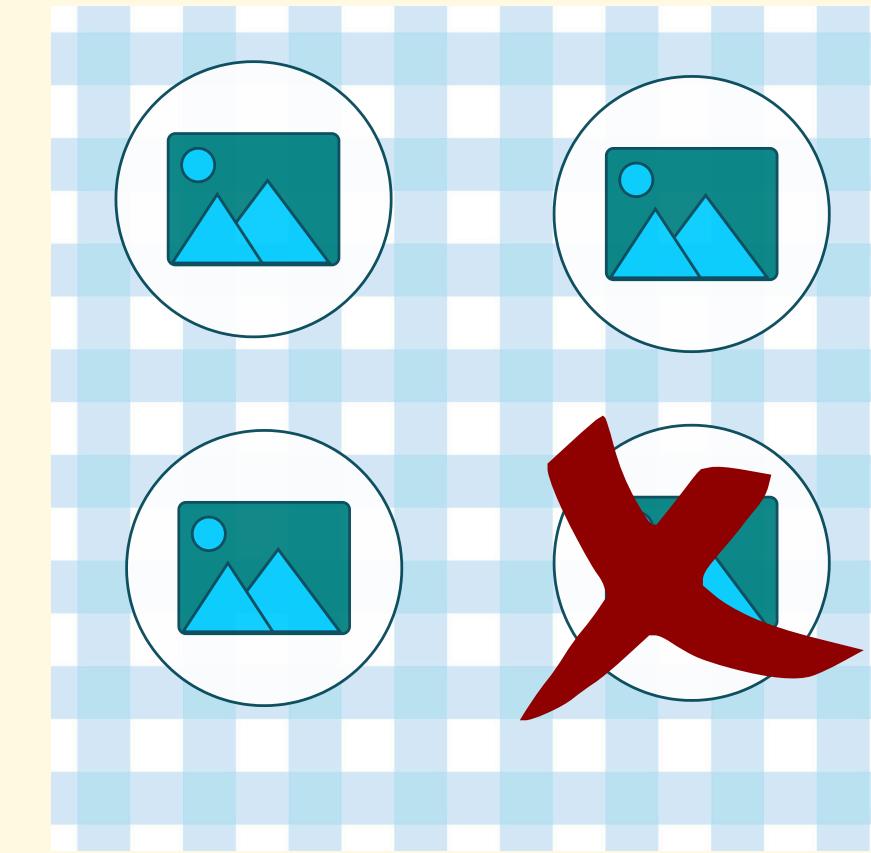
- Redimensionamiento



- Normalización



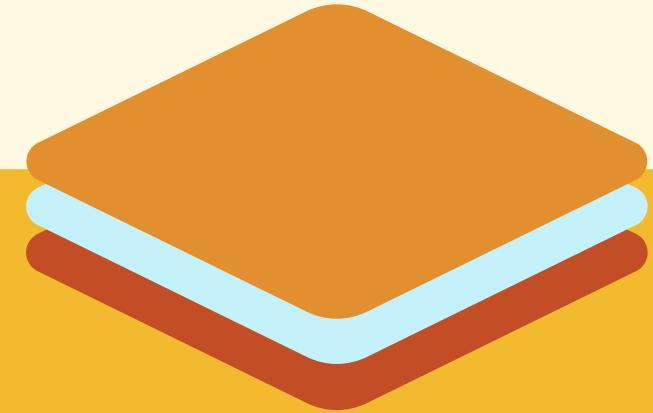
- Filtrado de la base de datos



Arquitectura de la Red Convolucional

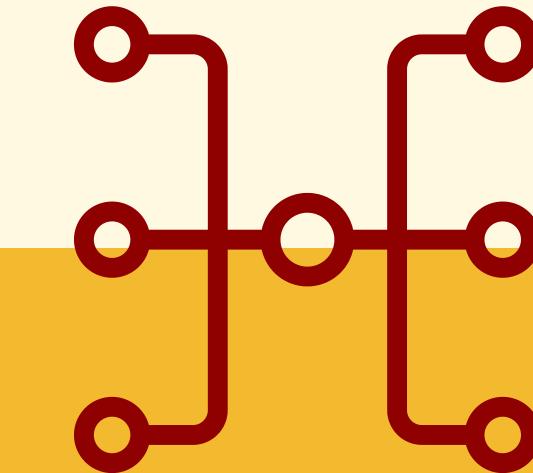
Transfer Learning

Uso de **EfficientNetB0** preentrenada en **ImageNet**.



Estructura del modelo:

- Input: Imágenes 224x224x3.
- EfficientNetB0: Extrae características, salida de 7x7x1280.
- Global Average Pooling: Convierte la salida en un vector de 1280 características.
- Dropout: Previene sobreajuste.
- Dense (Softmax): Clasifica en 4 categorías.



Resumen de parámetros:

Solo la capa densa es entrenable (aprox. 5,124 parámetros); EfficientNetB0 se congela inicialmente.



Arquitectura de la Red Convolucional

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 224, 224, 3)	0
efficientnetb0 (Functional)	(None, 7, 7, 1280)	4,049,571
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dropout (Dropout)	(None, 1280)	0
dense (Dense)	(None, 4)	5,124

Total params: 4,054,695 (15.47 MB)

Trainable params: 5,124 (20.02 KB)

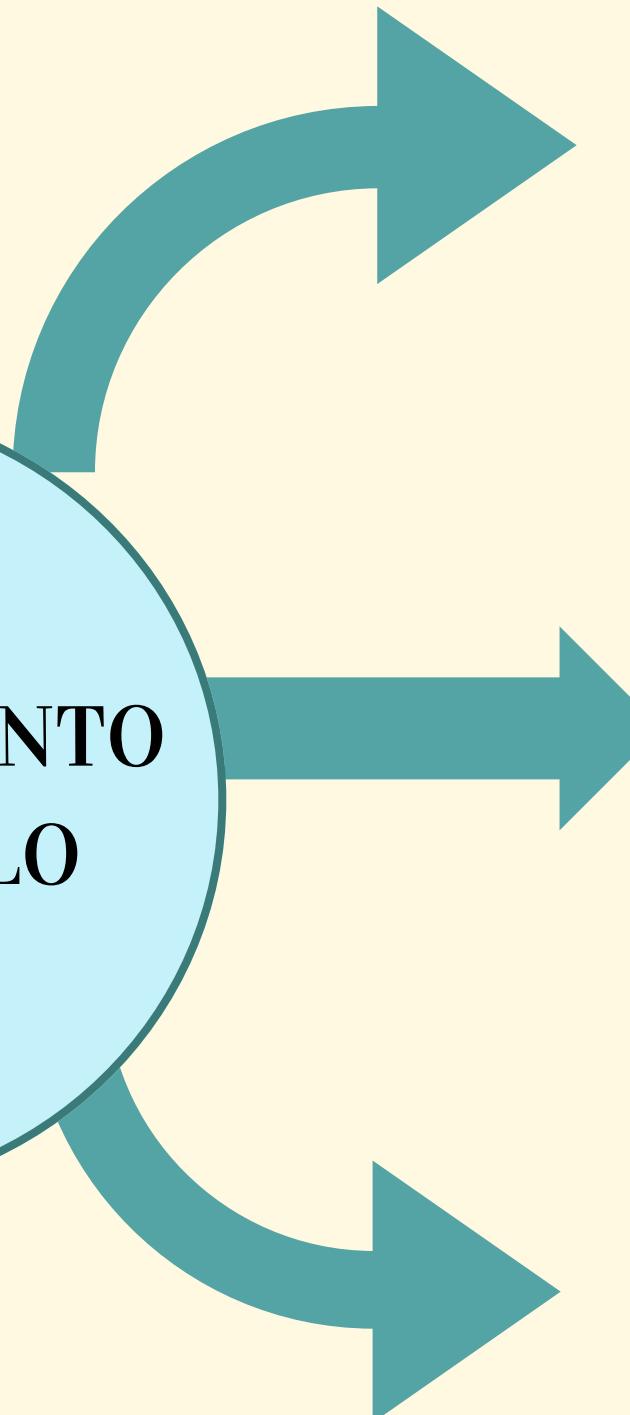
Non-trainable params: 4,049,571 (15.45 MB)

ENTRENAMIENTO Y FINE-TUNING

- Entrenamiento Inicial:
 - Entrenamiento con la base congelada usando Adam y categorical crossentropy.
 - División de datos: 70% entrenamiento, 15% validación, 15% test.
 - **Resultados iniciales (exactitud del 72%, AUC > 0.90).**
 - Fine-Tuning:
 - Descongelar capas superiores de EfficientNetB0 (a partir de cierta capa).
 - Recompilación con learning rate reducido ($1e-5$) y uso de class weights para desbalance.
 - Entrenamiento adicional de 10 épocas para ajustar los pesos finamente.



ENTRENAMIENTO DEL MODELO



- Separar el conjunto de datos en subconjuntos de entrenamiento (70%), testeo (15%) y validación (15%)
- Ajustar la tasa de aprendizaje y el número de épocas para asegurar una convergencia óptima.
- Se propone usar un modelo de validación para obtener una estimación más robusta del rendimiento del modelo.



MÉTRICAS DE EVALUACION

$$\text{Exactitud (Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Sensibilidad (Recall)} = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$
$$= \frac{2TP}{2TP + FP + FN}$$

$$\text{Specificity} = \frac{TN}{TN + FP}$$

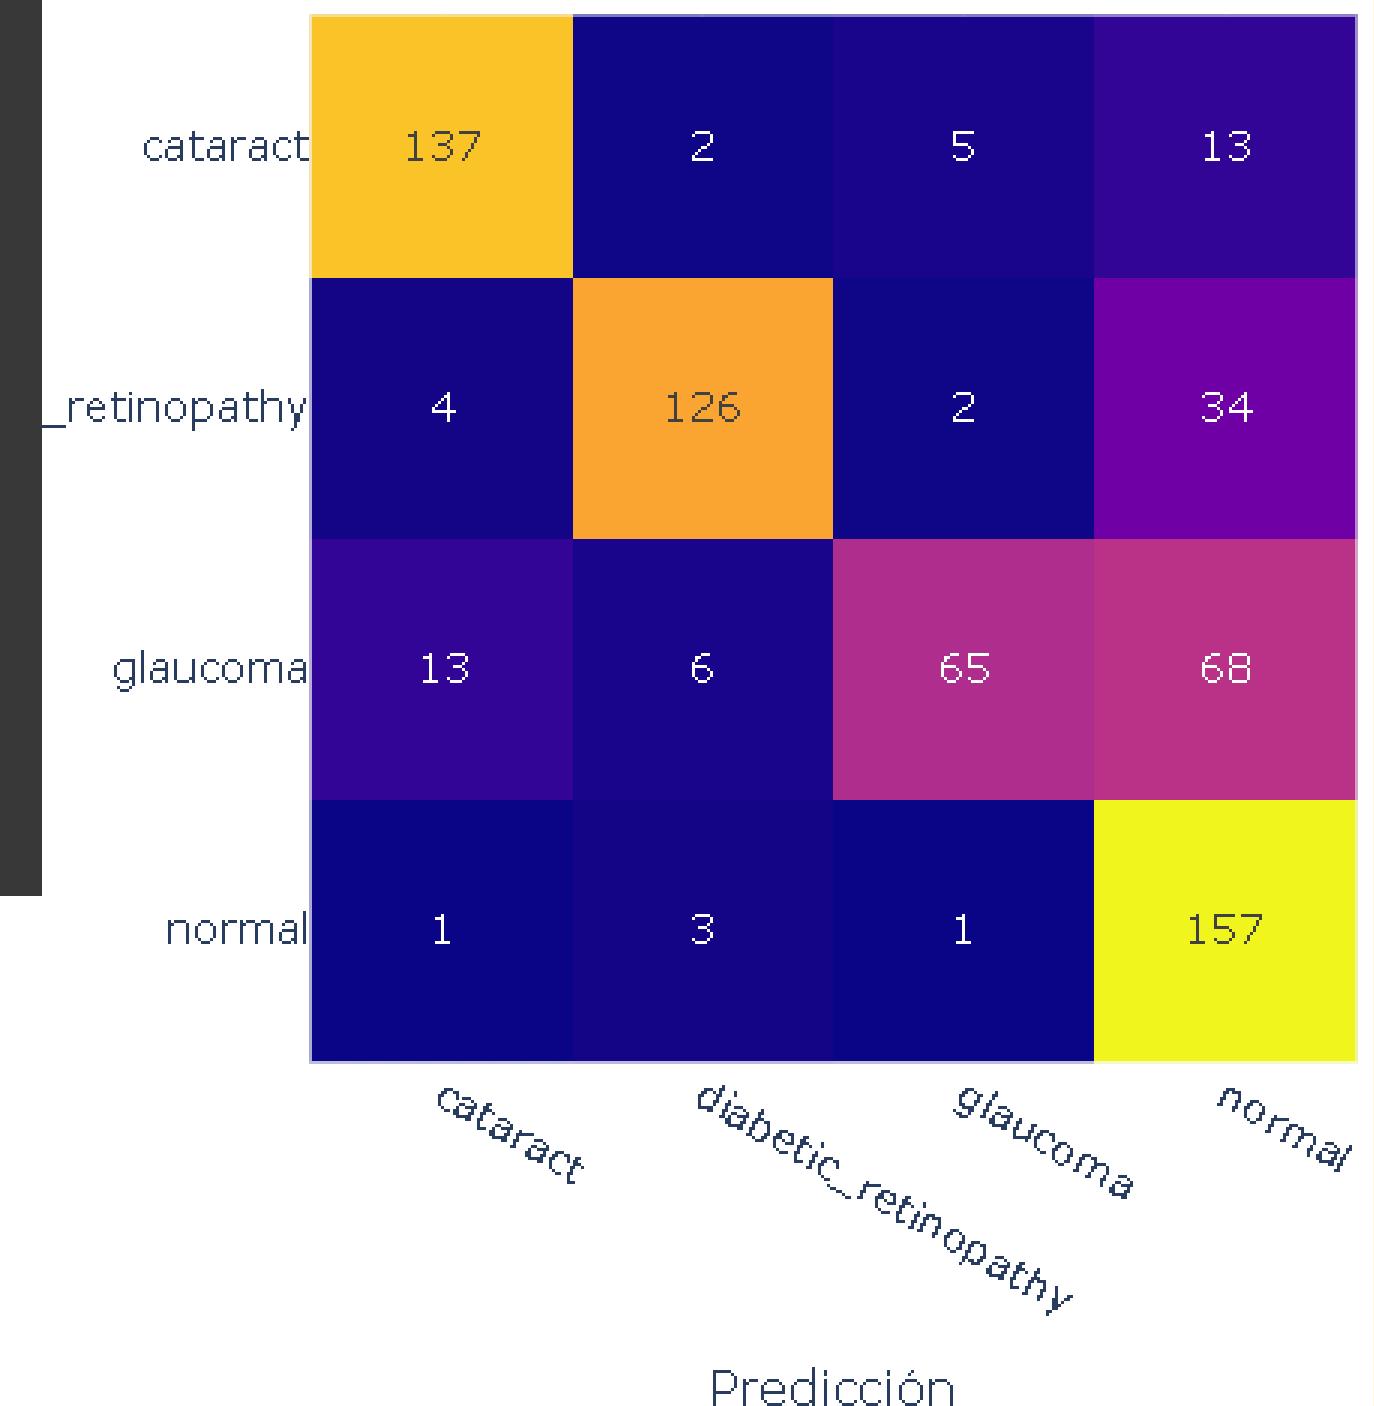
- TP (True Positives): Casos positivos correctamente clasificados.
- TN (True Negatives): Casos negativos correctamente clasificados.
- FP (False Positives): Casos negativos clasificados erróneamente como positivos.
- FN (False Negatives): Casos positivos clasificados erróneamente como negativos.

ENTRENAMIENTO INICIAL - MATRIZ DE CONFUSIÓN

Accuracy inicial en test: 0.728414442700157

Reporte de clasificación (inicial):

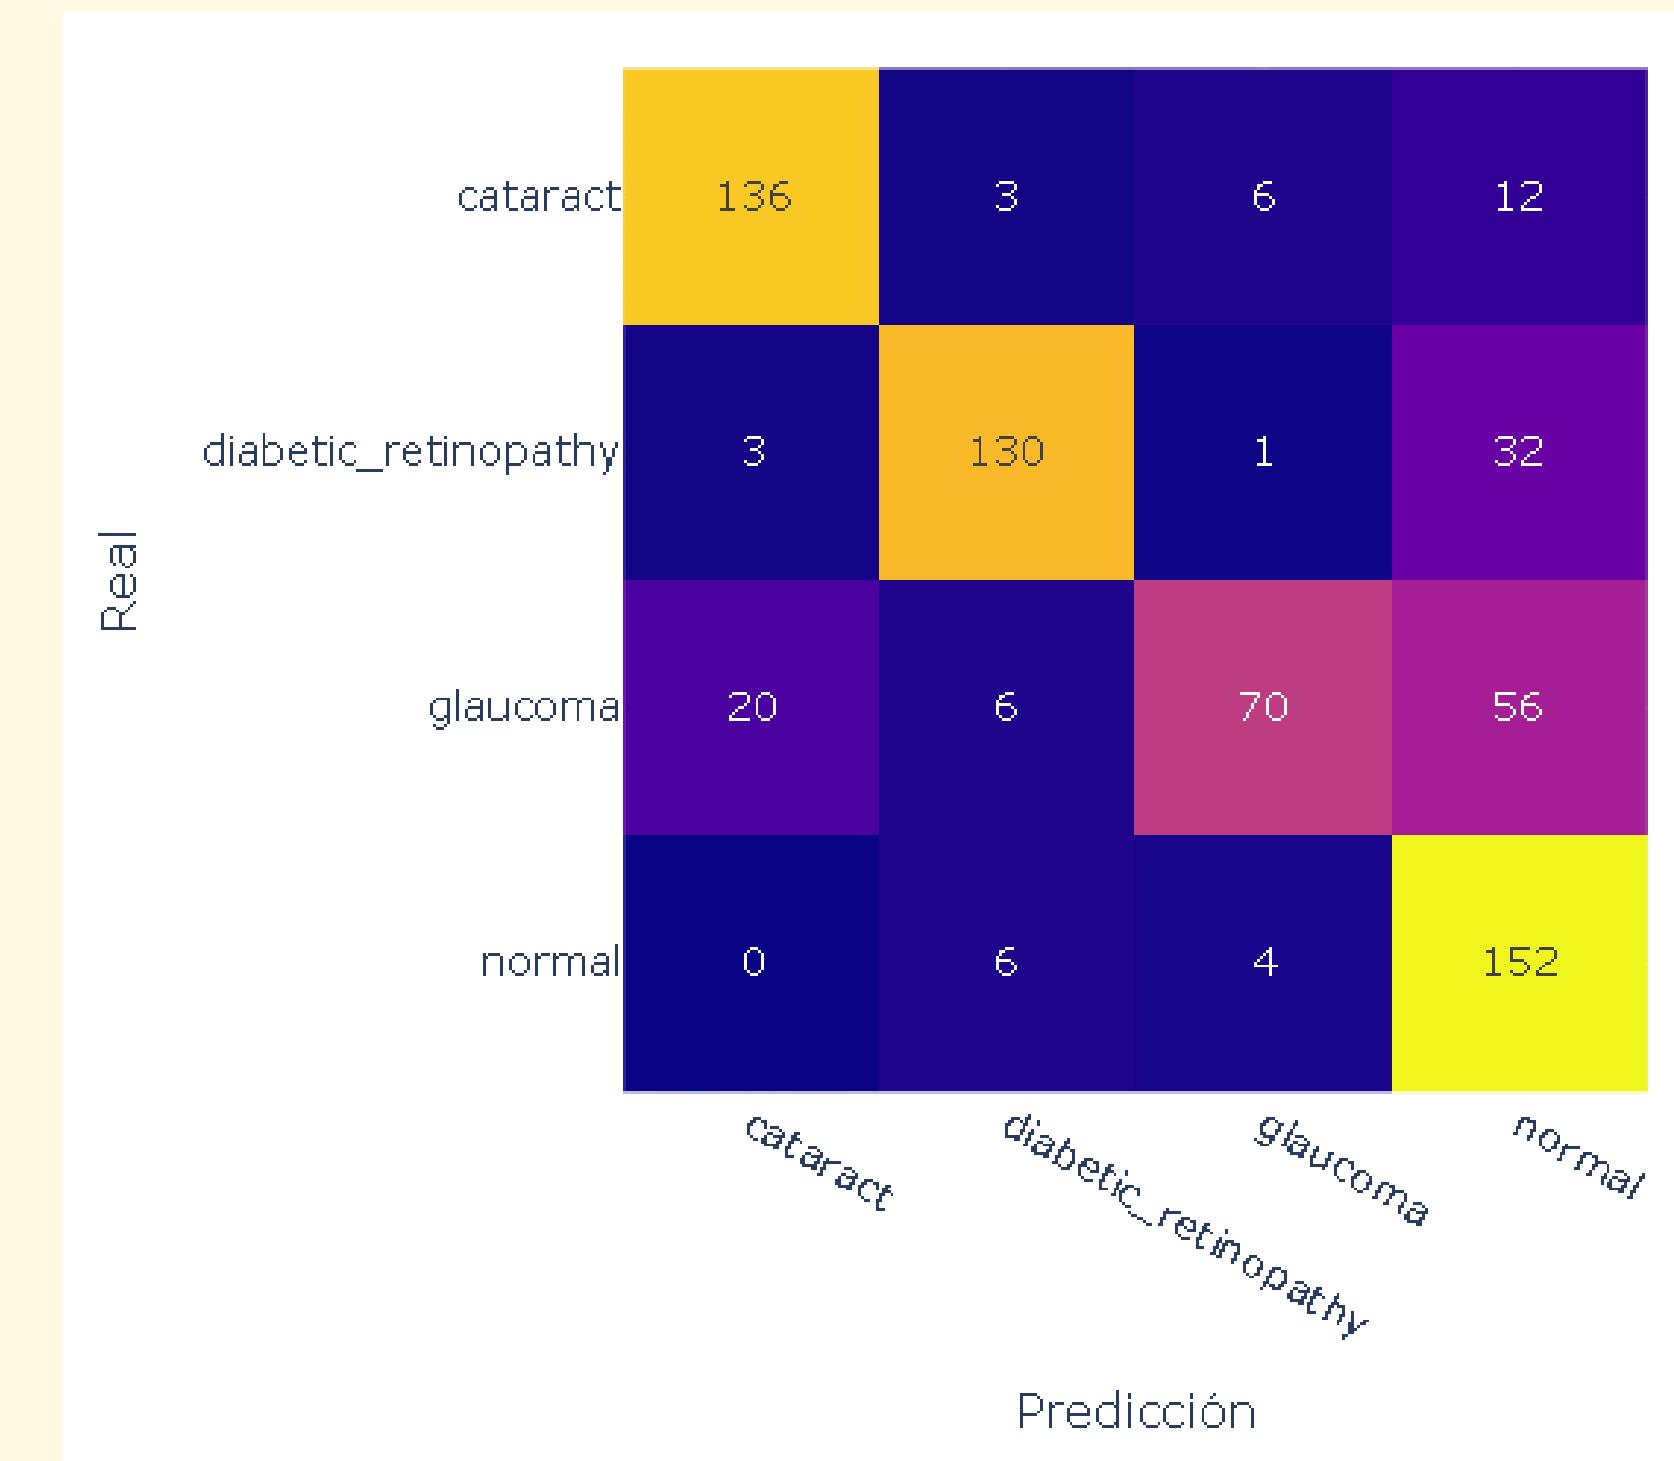
	precision	recall	f1-score	support
cataract	0.86	0.89	0.87	157
diabetic_retinopathy	0.92	0.72	0.80	166
glaucoma	0.95	0.38	0.54	152
normal	0.52	0.92	0.67	162
accuracy			0.73	637
macro avg	0.81	0.72	0.72	637
weighted avg	0.81	0.73	0.72	637



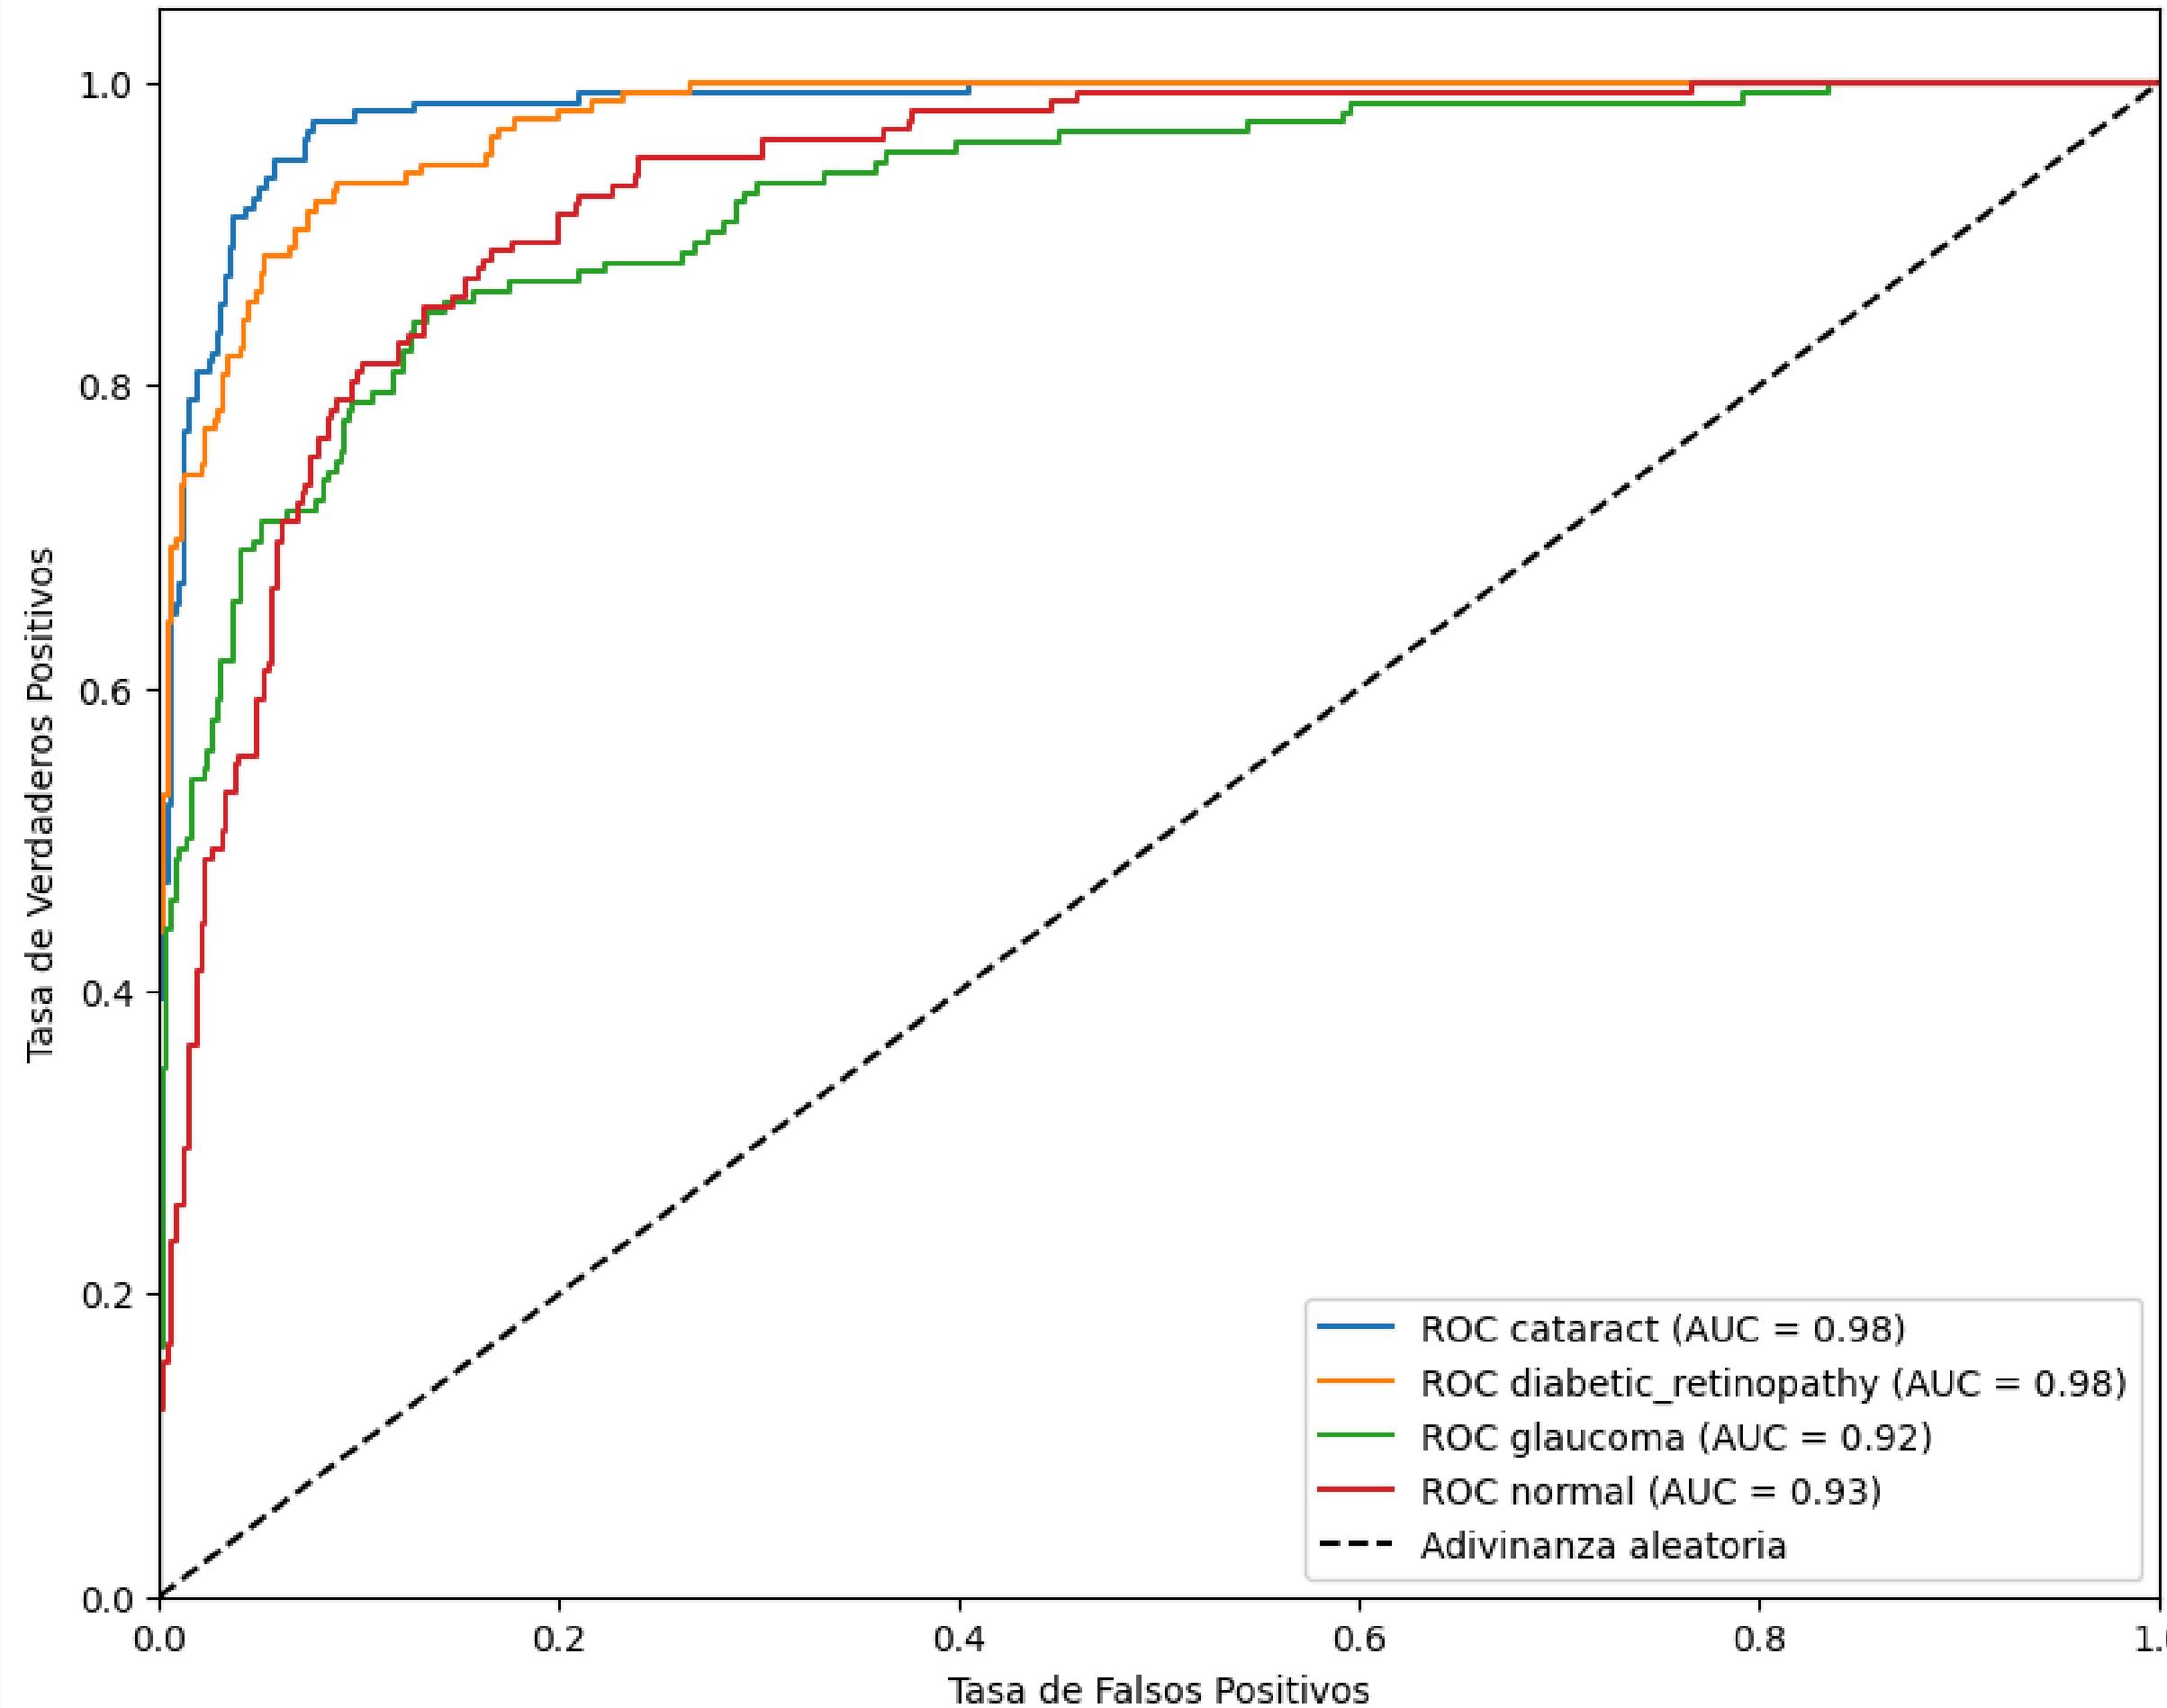
ENTRENAMIENTO FT- MATRIZ DE CONFUSIÓN

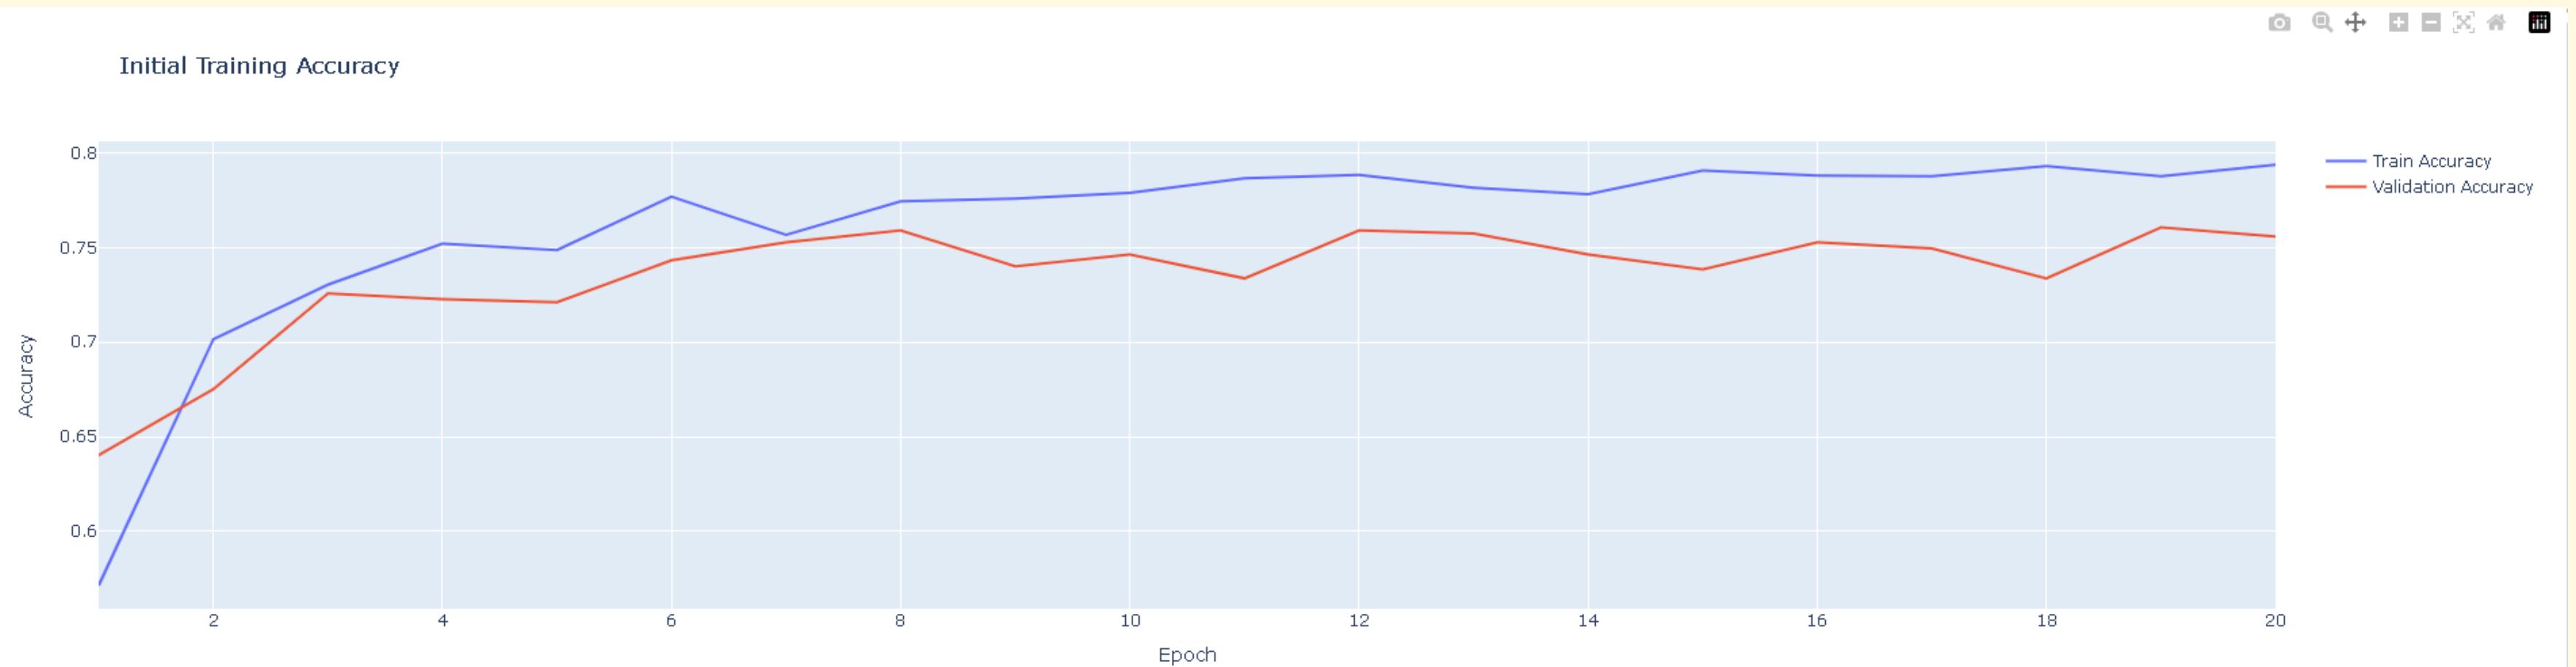
```
Accuracy final en test: 0.7660910518053375
Reporte final de clasificación:
      precision    recall  f1-score   support
  cataract       0.87     0.94     0.90     157
diabetic_retinopathy       0.94     0.72     0.82     166
  glaucoma       0.97     0.45     0.62     152
    normal       0.56     0.94     0.70     162

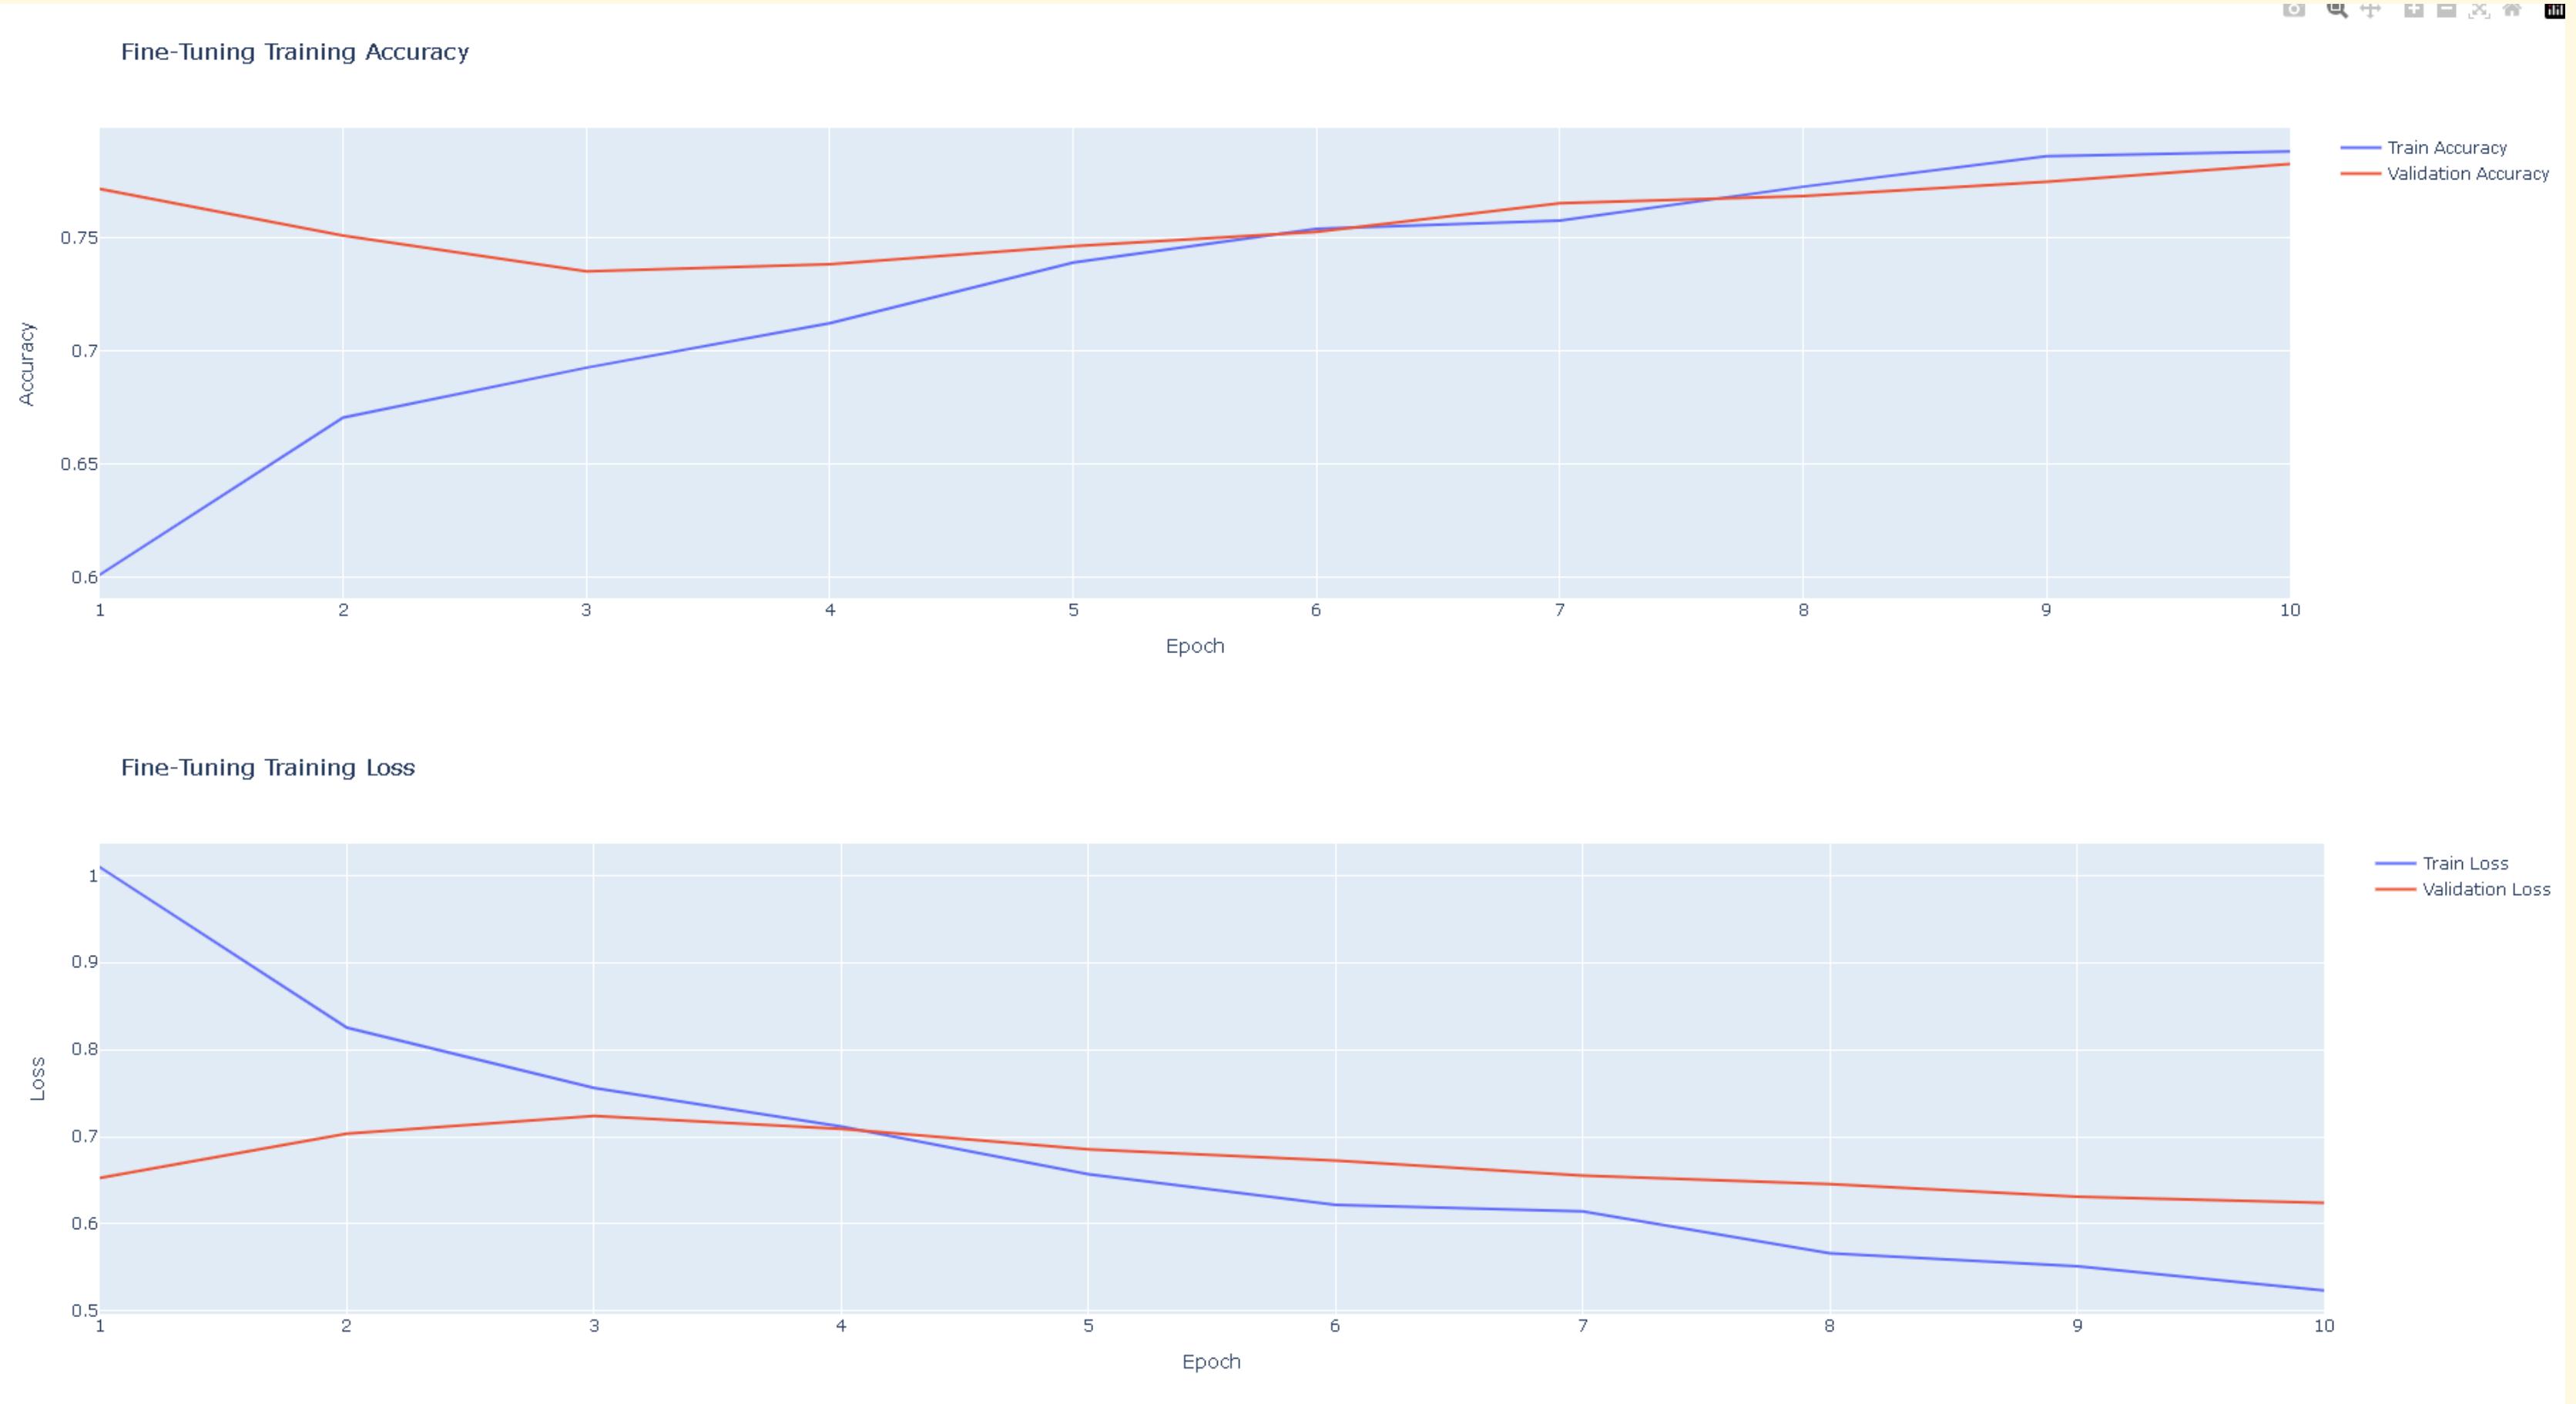
  accuracy         0.77
  macro avg       0.84     0.76     0.76     637
weighted avg       0.84     0.77     0.76     637
```

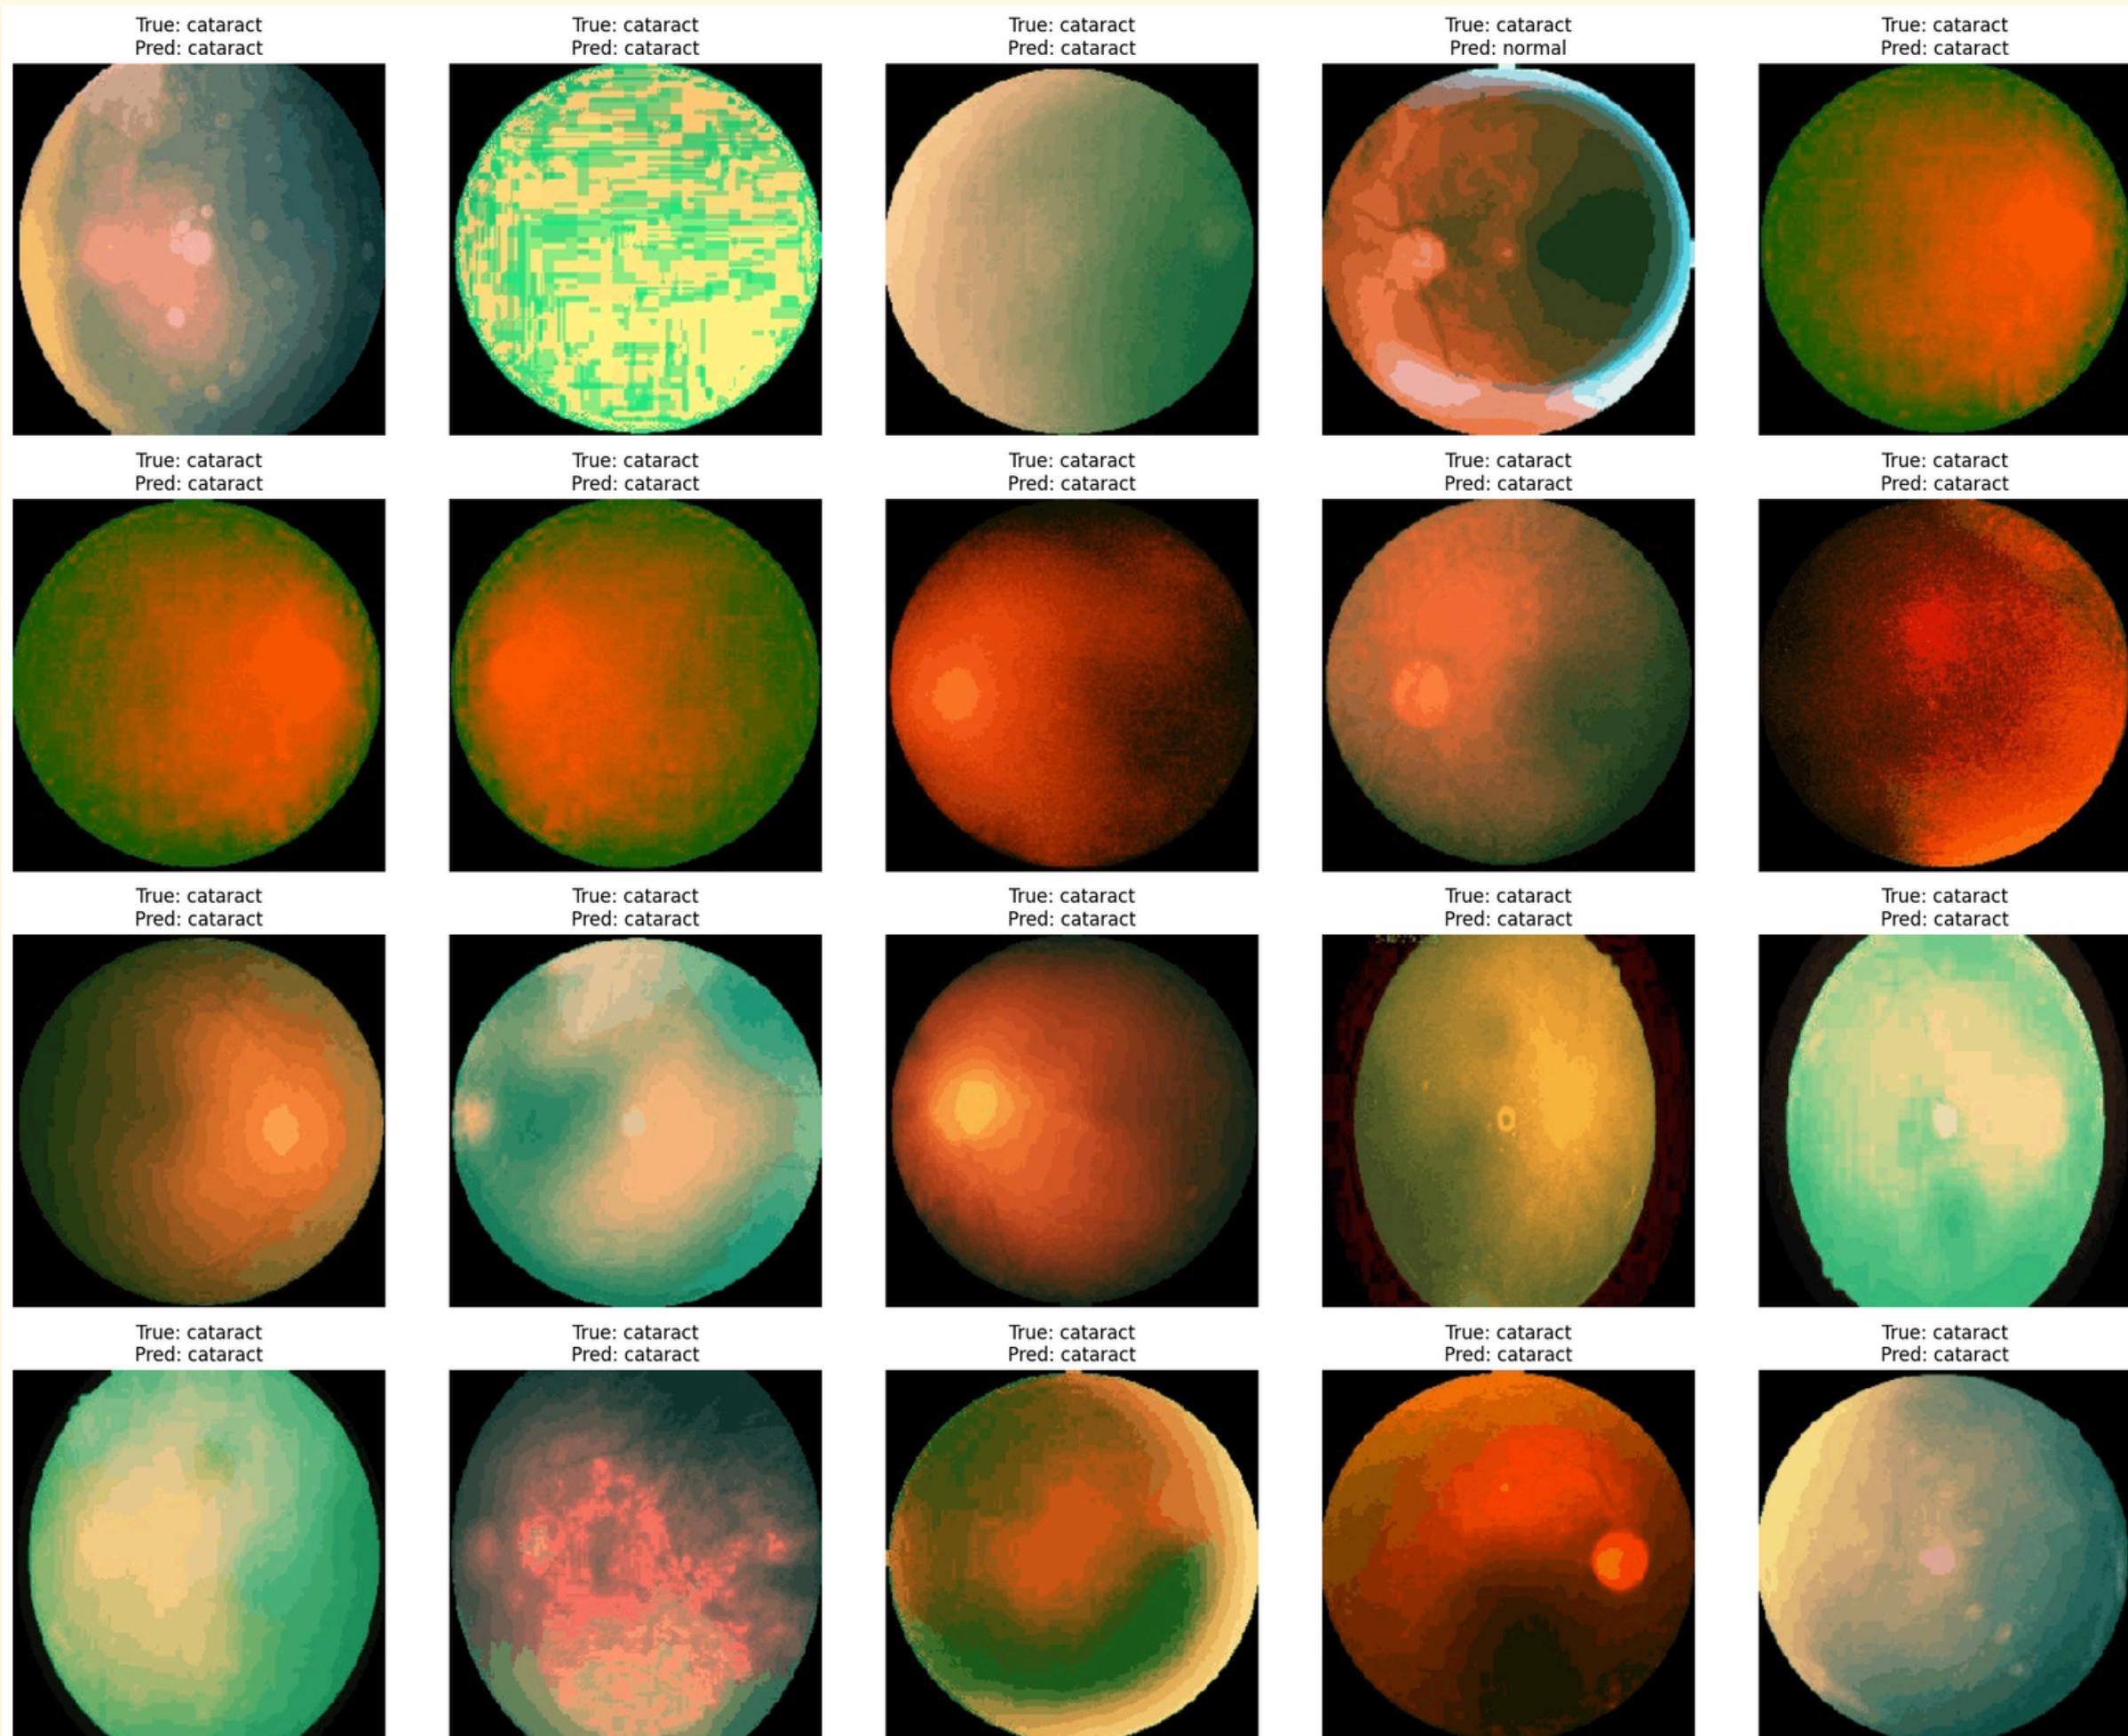


Curvas ROC para cada clase



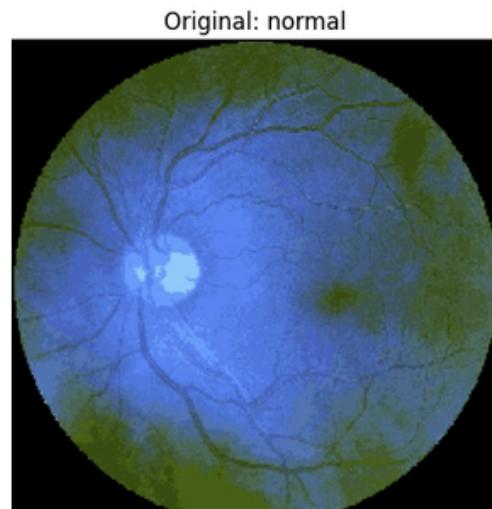
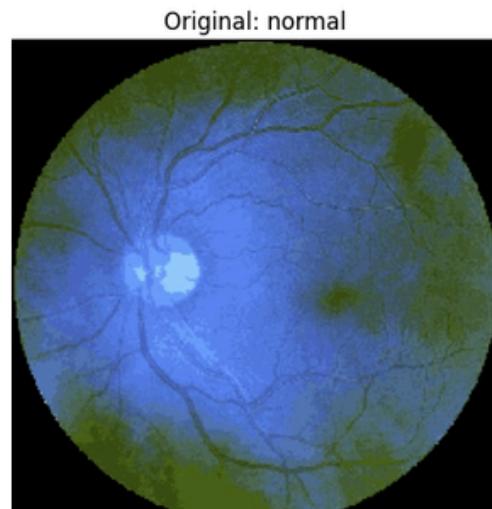
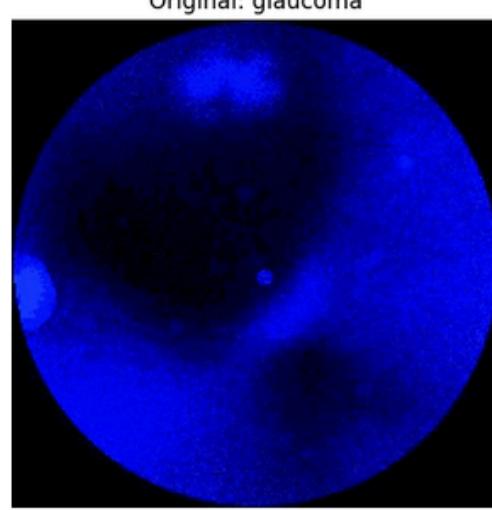
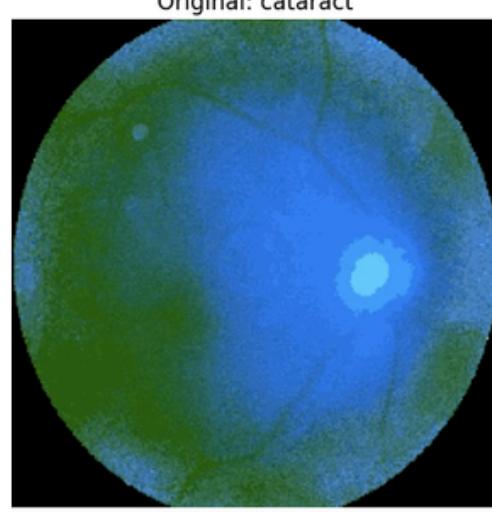
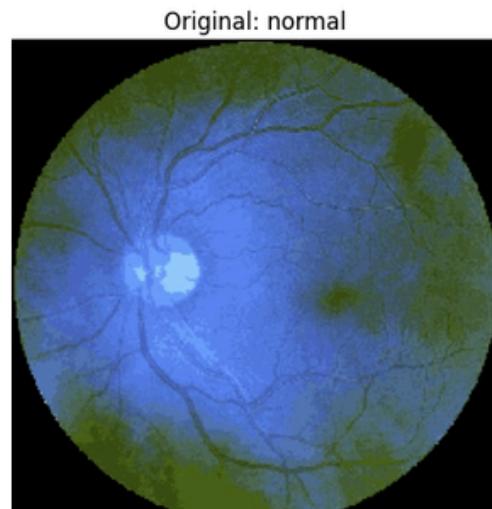
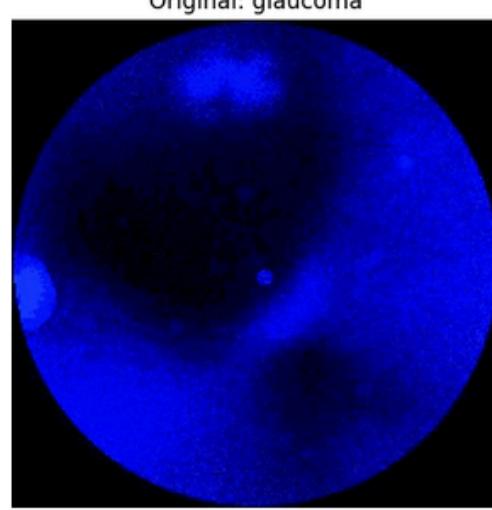
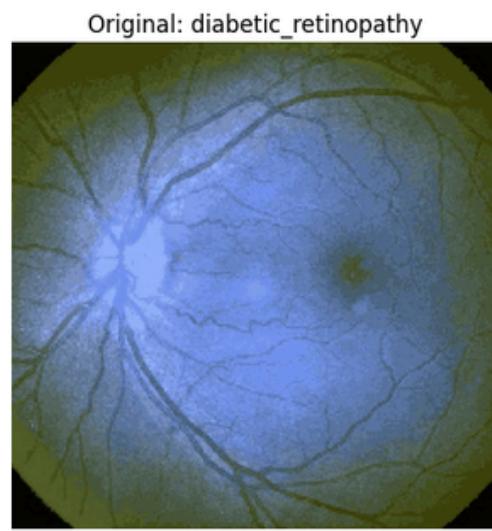
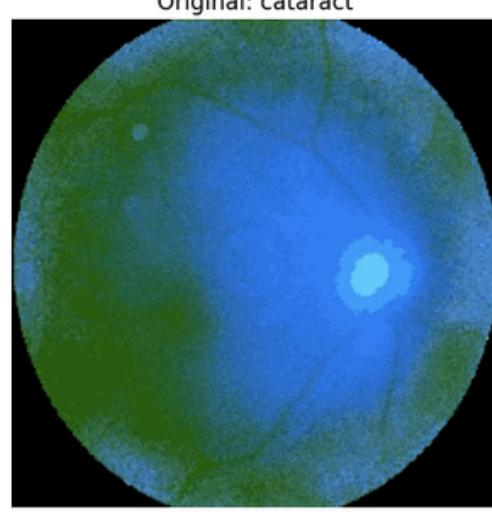






SALIENCY MAPS

- Visualizaciones que muestran la sensibilidad del modelo a cambios en cada píxel de la imagen, obtenidas a partir del gradiente de la salida respecto a la entrada.
- Objetivo:
- Identificar las regiones críticas que influyen en la predicción del modelo, facilitando la validación clínica.
- Importancia en Oftalmología:
- Permiten confirmar que el modelo se enfoca en áreas relevantes (por ejemplo, vasos sanguíneos y zonas afectadas) y no en artefactos o áreas irrelevantes.



○

Perspectivas Futuras

Implementación y
Optimización :
GitHub

Integración de Técnicas
Interpretativas
Avanzadas: Saliency Maps con
ayuda de expertos

Ampliación del
Conjunto de Datos.

Mejoras en la
Arquitectura: ViT

Validación en
Entornos Reales

04-Bibliografia



- <https://acortar.link/VAuz9g>: Quantitative approaches in multimodal fundus imaging: State of the art and future perspectives
- https://www.sas.com/es_co/insights/analytics/computer-vision.html#:~:text=Historia%20del%20reconocimiento%20de%20im%C3%A1genes,categor%C3%ADas%2C%20como%20c%C3%ADrculos%20y%20cuadrados.: Reconocimiento de Imágenes
- Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs
- U-net: Convolutional networks for biomedical image segmentation
- Blindness and Visual Impairment
- A systematic review of retinal fundus image segmentation and classification methods using convolutional neural networks



¡MUCHAS GRACIAS!